


分布式计算

邱怡轩



今天的主题

- ADMM 算法 (二)
- 一致性优化问题



回顾：ADMM

ADMM

- Minimize $f(x) + g(z)$
- Subject to $Ax + Bz = c$
- x : n 维向量
- z : m 维向量
- A [$p \times n$], B [$p \times m$], c [$p \times 1$]: 约束条件
- $f(\cdot)$, $g(\cdot)$: 凸函数

ADMM 算法

- $x^{k+1} = \operatorname{argmin}_x f(x) + \frac{\rho}{2} \|Ax + Bz^k - c + u^k\|^2$
- $z^{k+1} = \operatorname{argmin}_z g(z) + \frac{\rho}{2} \|Ax^{k+1} + Bz - c + u^k\|^2$
- $u^{k+1} = u^k + Ax^{k+1} + Bz^{k+1} - c$

例：LAD

- 原问题： $\min_x \|Ax - b\|_1$
- ADMM形式：
- Minimize $\|z\|_1$
- Subject to $Ax - z = b$

例：LAD

- $x^{k+1} = (A'A)^{-1}A'(b + z^k - u^k)$
- $z^{k+1} = S_{1/\rho}(Ax^{k+1} - b + u^k)$
- $u^{k+1} = u^k + Ax^{k+1} - z^{k+1} - b$

- $S_\kappa(a)$ 称为 Soft-thresholding 运算符

$$S_\kappa(a) = \begin{cases} a - \kappa & a > \kappa \\ 0 & |a| \leq \kappa \\ a + \kappa & a < -\kappa, \end{cases}$$

例：Lasso

- 原问题： $\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1$
- ADMM形式：
- Minimize $\frac{1}{2} \|Ax - b\|^2 + \lambda \|z\|_1$
- Subject to $x - z = 0$

例：Lasso

- $x^{k+1} = (A'A + \rho I)^{-1}(A'b + \rho(z^k - u^k))$
- $z^{k+1} = S_{\lambda/\rho}(x^{k+1} + u^k)$
- $u^{k+1} = u^k + x^{k+1} - z^{k+1}$

实现

- 参见 [lec12-admm-lad.ipynb](#)
- 练习 [lec12-admm-lasso.ipynb](#)

适用范围

- “通用” 的分布式计算框架
 - 一致性优化 (Consensus)
 - 共享优化 (Sharing)



一致性优化问题

优化问题

- 考虑一个可分的优化问题

$$\text{minimize } f(x) = \sum_{i=1}^N f_i(x)$$

- $x \in \mathbf{R}^n$, $f_i(x)$ 是凸函数

- 注意 x 指的是抽象的参数，不是数据
- 数据通常包括在 f_i 中

一致性问题

- 转换成 ADMM 形式
- Minimize $\sum_{i=1}^N f_i(\mathbf{x}_i)$
- Subject to $\mathbf{x}_i - \mathbf{z} = 0, i = 1, \dots, N$
- 注意, 此时需要被优化的参数包括 $\mathbf{z}, \mathbf{x}_1, \dots, \mathbf{x}_N$, 共 $(N + 1)n$ 个
- 全局一致性问题: 所有局部变量相等

迭代算法

$$x_i^{k+1} := \operatorname{argmin}_{x_i} \left(f_i(x_i) + y_i^{kT} (x_i - z^k) + (\rho/2) \|x_i - z^k\|_2^2 \right)$$

$$z^{k+1} := \frac{1}{N} \sum_{i=1}^N \left(x_i^{k+1} + (1/\rho) y_i^k \right)$$

$$y_i^{k+1} := y_i^k + \rho(x_i^{k+1} - z^{k+1}).$$

迭代算法

- 可以证明, $z^k = \bar{x}^k$
- \bar{x}^k 是 x_1^k, \dots, x_N^k 的平均
- 算法可以进一步化简

$$x_i^{k+1} := \operatorname{argmin}_{x_i} \left(f_i(x_i) + y_i^{kT} (x_i - \bar{x}^k) + (\rho/2) \|x_i - \bar{x}^k\|_2^2 \right)$$

$$y_i^{k+1} := y_i^k + \rho(x_i^{k+1} - \bar{x}^{k+1}).$$

意义

$$\text{minimize } f(x) = \sum_{i=1}^N f_i(x),$$

$$x_i^{k+1} := \underset{x_i}{\operatorname{argmin}} \left(f_i(x_i) + y_i^{kT} (x_i - \bar{x}^k) + (\rho/2) \|x_i - \bar{x}^k\|_2^2 \right)$$

$$y_i^{k+1} := y_i^k + \rho(x_i^{k+1} - \bar{x}^{k+1}).$$

- 许多统计和机器学习模型都可以写成这种形式（似然函数平均）
- 每个 x_i^k 的更新是完全并行的（Map）
- \bar{x}^k 负责收集每个分块的信息（Reduce）

例：线性回归

$$\text{minimize } f(x) = \sum_{i=1}^N f_i(x),$$

$$x_i^{k+1} := \underset{x_i}{\operatorname{argmin}} \left(f_i(x_i) + y_i^{kT} (x_i - \bar{x}^k) + (\rho/2) \|x_i - \bar{x}^k\|_2^2 \right)$$

$$y_i^{k+1} := y_i^k + \rho(x_i^{k+1} - \bar{x}^{k+1}).$$

- 如果原问题是最小二乘回归
- 将数据按观测切为 N 块
- 那么每个 f_i 就是每个分块上的损失函数
- 每个分块上各自求解一个线性方程组

正则项

- 有时我们需要对参数加入全局的正则项
- Minimize $\sum_{i=1}^N f_i(\mathbf{x}_i) + g(z)$
- Subject to $x_i - z = 0, i = 1, \dots, N$

迭代算法

$$x_i^{k+1} := \operatorname{argmin}_{x_i} \left(f_i(x_i) + y_i^{kT} (x_i - z^k) + (\rho/2) \|x_i - z^k\|_2^2 \right)$$

$$z^{k+1} := \operatorname{argmin}_z \left(g(z) + \sum_{i=1}^N (-y_i^{kT} z + (\rho/2) \|x_i^{k+1} - z\|_2^2) \right)$$

$$y_i^{k+1} := y_i^k + \rho(x_i^{k+1} - z^{k+1}).$$

简化形式

$$x_i^{k+1} := \operatorname{argmin}_{x_i} \left(f_i(x_i) + (\rho/2) \|x_i - z^k + u_i^k\|_2^2 \right)$$

$$z^{k+1} := \operatorname{argmin}_z \left(g(z) + (N\rho/2) \|z - \bar{x}^{k+1} - \bar{u}^k\|_2^2 \right)$$

$$u_i^{k+1} := u_i^k + x_i^{k+1} - z^{k+1}.$$

例：Lasso

$$\blacksquare \min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1$$

$$A = \begin{bmatrix} A_1 \\ \vdots \\ A_N \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ \vdots \\ b_N \end{bmatrix},$$

$$x_i^{k+1} := (A_i^T A_i + \rho I)^{-1} (A_i^T b_i + \rho(z^k - u_i^k))$$



$$z^{k+1} := S_{\lambda/\rho N}(\bar{x}^{k+1} + \bar{u}^k)$$

$$u_i^{k+1} := u_i^k + x_i^{k+1} - z^{k+1}$$

典型问题


- $\min_x \overset{\text{损失函数}}{l(Ax - b)} + \overset{\text{正则项}}{r(x)}$
- x : 参数向量
- A, b : 数据矩阵/向量

数据切分



- 按行切分
- 每个分块包含一部分观测
- 每个分块包含所有的变量

数据切分



- $l(Ax - b) = \sum_{i=1}^N l_i(Ax_i - b_i)$
- Minimize $\sum_{i=1}^N l_i(Ax_i - b_i) + r(z)$
- Subject to $x_i - z = 0, i = 1, \dots, N$

数据切分

$$A = \begin{bmatrix} A_1 \\ \vdots \\ A_N \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ \vdots \\ b_N \end{bmatrix},$$

- $l(Ax - b) = \sum_{i=1}^N l_i(Ax_i - b_i)$
- Minimize $\sum_{i=1}^N l_i(Ax_i - b_i) + r(z)$
- Subject to $x_i - z = 0, \quad i = 1, \dots, N$

迭代算法

$$x_i^{k+1} := \operatorname{argmin}_{x_i} \left(l_i(A_i x_i - b_i) + (\rho/2) \|x_i - z^k + u_i^k\|_2^2 \right)$$

$$z^{k+1} := \operatorname{argmin}_z \left(r(z) + (N\rho/2) \|z - \bar{x}^{k+1} - \bar{u}^k\|_2^2 \right)$$

$$u_i^{k+1} := u_i^k + x_i^{k+1} - z^{k+1}.$$

扩展阅读

- <https://joegaotao.github.io/2014/02/11/admm-stat-compute/>